

World Model (RSSM) + VLM-based Scorer для планирования агента в MiniGrid

Чирков Михаил

7 июля 2026 г.

Аннотация

В работе исследуется подход к навигации агента в среде MiniGrid-Empty-6x6-v0 без использования разреженного reward от среды. Агент строит рекуррентную модель мира (RSSM, DreamerV3) и планирует действия через MPC с оценкой воображаемых траекторий. В качестве функции скоринга сравниваются два подхода: встроенный reward predictor world model (RSSM reward head) и CLIP-ViT-B/32, измеряющий косинусную близость раскодированных кадров к текстовому промпту «a green goal square». Эксперименты на 10 эпизодах показывают, что reward-базированный скоринг даёт 100% успеха со средним возвратом 0.93 ± 0.03 , в то время как лучшая CLIP-стратегия (argmax, discounted sum) достигает 0.92 ± 0.05 при 100% успеха.

1. Среда и данные

1.1. Среда

Среда MiniGrid-Empty-6x6-v0 выбрана из-за своей простоты для быстрой отладки и проведения экспериментов. Агент управляется в сетке 6×6 : цель — достичь зелёной клетки.

- **Observation space:** RGB-рендер частичного обзора (перспектива агента), размер кадра $3 \times 56 \times 56$.
- **Action space:** обрезан до трёх действий — turn left, turn right, forward.
- **Reward:** $r = 1$ при достижении цели, иначе 0 (sparse reward).
- **Max episode length:** $T_{\max} = 72$ шага.

1.2. Сбор данных

- Две политики в соотношении 50/50:
 - **Random policy:** равномерный выбор из допустимых действий.
 - **ScriptedPolicy:** эвристика навигации к цели с $\epsilon = 0.05$ случайных действий.
- Начальный сбор: 200 эпизодов.
- В каждой итерации обучения (всего 200 итераций, 10 000 gradient steps, replay ratio 50): ещё 10 эпизодов. После этого дообучение (+6k gradient steps).
- Всего собрано ≈ 2200 эпизодов.
- Размер кругового буфера: 500 000 переходов.
- Сиды зафиксированы через seed_everything(42).

1.3. Архитектура world model

RSSM на основе DreamerV3:

- **EncoderConv**: CNN $3 \times 56 \times 56 \rightarrow 1024$.
- **RecurrentModel**: GRUCell, hidden size $h = 128$.
- **PriorNet / PosteriorNet**: 2-layer MLP, категориальный латент $16 \times 16 = 256$.
- **DecoderConv**: symmetric transposed-CNN.
- **RewardModel**: two-hot reward predictor (21 bins, symlog-encoded).
- Активации: SiLU, нормализация: LayerNorm.
- Обучение: Adam, $lr = 10^{-4}$, batch 32×64 .

2. VLM-based scorer

2.1. Модель

Используется CLIP ViT-B/32 с весами laion2b_s34b_b79k (библиотека open_clip). Выбор обусловлен:

- достаточной лёгкостью для iterative planning (ViT-B/32, 86M);
- предобученным семантическим alignment изображение–текст;
- доступностью через open-clip-torch.

2.2. Текстовая цель

Единственный промпт: "a green goal square". (Метод set_goal() позволяет менять цель; другие промпты не исследовались).

2.3. Препроцессинг и получение score

Для каждого imagined-кадра $\hat{o}_t$ ($3 \times 56 \times 56$, symlog-представление):

1. $\mathbf{o}'_t = \text{symexp}(\hat{o}_t)$, клиппинг в $[0, 1]$.
2. Билинейный ресайз до 224×224 .
3. Нормализация со статистиками ImageNet.
4. Прогон через CLIP image encoder, $\mathbf{e}_t^{\text{img}} = \text{normalize}(\text{CLIP}_{\text{img}}(\mathbf{o}_t^{\text{norm}}))$.

Текстовый эмбеддинг цели вычисляется один раз: $\mathbf{e}^{\text{text}} = \text{normalize}(\text{CLIP}_{\text{text}}(\text{"a green goal square"}))$.

Сходство: $\text{sim}_t = \langle \mathbf{e}_t^{\text{img}}, \mathbf{e}^{\text{text}} \rangle$.

2.4. Агрегация по горизонту

Для траектории τ длины $H = 15$ с $\gamma = 0.99$:

$$\text{discounted_sum: } S(\tau) = \sum_{t=1}^H \gamma^{t-1} \cdot \text{sim}_t,$$

$$\text{max: } S(\tau) = \max_{1 \leq t \leq H} \text{sim}_t,$$

$$\text{max_discounted: } S(\tau) = \max_{1 \leq t \leq H} (\gamma^{t-1} \cdot \text{sim}_t).$$

Основной режим — `discounted_sum`: учитывает всю траекторию, дисконтируя дальние шаги, что соответствует задаче достижения цели с минимальным числом шагов.

Reward-scorer (baseline без VLM). Использует встроенный `reward predictor world model` (`two-hot`, 21 бин в $[-0.5, 1.5]$, декодируется через `decode_two_hot`). Режимы агрегации те же. Не использует CLIP — baseline для сравнения.

3. Планирование (MPC)

Планирование выполняется в латентном пространстве RSSM. На каждом шаге сэмпляются $N = 64$ кандидата длины $H = 15$, «воображаются» через `prior RSSM`, оцениваются скором (CLIP или `reward`), выбирается первое действие лучшего.

3.1. Сэмплеры кандидатов

Uniform Candidates: $a_t \sim \mathcal{U}(\mathcal{A})$, $\mathcal{A} = \{\text{Left, Right, Forward}\}$.

Heuristic Candidates (biased random shooting):

$$P(\text{Forward}) = 0.8, \quad P(\text{Left}) = P(\text{Right}) = 0.1.$$

Смещение мотивировано тем, что в `Empty-6x6` движение вперёд почти всегда полезно; равномерное сэмплирование при $N = 64$ порождает большинство бессмысленных траекторий.

СЕМ: $K = 3$ итерации, доля элиты $e = 0.1$ ($N_{\text{elite}} = 6$), сглаживание $\alpha = 0.5$. На каждой итерации:

1. Сэмплировать N траекторий из $\{\mathbf{p}_t\}_{t=1}^H$.
2. Оценить каждую.
3. Выбрать N_{elite} лучших.
4. Обновить:

$$\tilde{p}_{t,a} = \frac{\sum_{i \in \text{elite}} \mathbb{1}[a_t^{(i)} = a] + \varepsilon}{N_{\text{elite}} + |\mathcal{A}| \varepsilon}, \quad \varepsilon = 10^{-3}, \quad \mathbf{p}_t \leftarrow \alpha \tilde{\mathbf{p}}_t + (1 - \alpha) \mathbf{p}_t.$$

Инициализация: $\mathbf{p}_t = \left[\frac{1}{3}, \frac{1}{3}, \frac{1}{3} \right]$. Возвращается лучшая траектория за все итерации.

3.2. МРС-цикл

На каждом шаге эпизода:

1. Закодировать $\mathbf{o}_t$ через encoder и posterior net в $(\mathbf{h}_t, \mathbf{z}_t)$.
2. Сэмплировать N кандидатов $\{a_{1:H}^{(n)}\}_{n=1}^N$.
3. Prior rollouts: $\mathbf{s}_{1:H}^{(n)} = \text{RSSM}_{\text{prior}}(\mathbf{h}_t, \mathbf{z}_t, a_{1:H}^{(n)})$.
4. $S^{(n)} = \text{score}(\mathbf{s}_{1:H}^{(n)})$ (CLIP или reward).
5. Выбрать a_0^* .
6. Выполнить a_0^* в среде.

3.3. Выбор действия

- **argmax:** $a_0^* = a_0^{(n^*)}$, $n^* = \arg \max_n S^{(n)}$.
- **agg (aggregated):** группировка по первому действию, усреднение скоров:

$$a_0^* = \arg \max_a \frac{1}{|\mathcal{N}_a|} \sum_{n \in \mathcal{N}_a} S^{(n)}, \quad \mathcal{N}_a = \{n : a_0^{(n)} = a\}.$$

4. Эксперимент

4.1. Протокол

- 10 эпизодов на каждую из 9 стратегий.
- Seed среды для eval: $42 + 999 = 1041$.
- Seed генератора случайных чисел: `seed_everything(42)`.
- Метрики:
 - **Return:** $\sum r_t$, где $r_t = 1$ при достижении цели, иначе 0. Максимум: 1.
 - **Success rate:** доля эпизодов с return > 0.
- Среда: MiniGrid-Empty-6x6-v0 (случайные старт и цель).

4.2. Результаты




Рис. 1: Средний return по 9 стратегиям (10 эпизодов).

Ключевые наблюдения:

Таблица 1: Сравнение 9 стратегий ($N_{\text{episodes}} = 10$, seed = 1041).

Стратегия	Mean return $\pm$ std	Success rate
CLIP Heuristic RS agg discounted_sum	0.886 ± 0.028	100%
CLIP Heuristic RS argmax discounted_sum	0.919 ± 0.045	100%
CLIP Heuristic RS agg max	0.066 ± 0.117	30%
CLIP Heuristic RS argmax max	0.469 ± 0.326	80%
Reward argmax discounted_sum	0.927 ± 0.015	100%
Reward agg discounted_sum	0.932 ± 0.031	100%
Reward argmax max	0.883 ± 0.048	100%
Reward agg max	0.928 ± 0.028	100%
Random	0.000 ± 0.000	0%

1. discounted_sum работает отлично во всех конфигурациях (100% success, return > 0.88).
2. max-режим для CLIP резко деградирует: agg max — лишь 30% success с return 0.07.
3. Reward-based скоринг стабильнее CLIP: все 8 комбинаций дают 100% success, разброс return 0.88–0.93.
4. Лучший CLIP (argmax discounted_sum, 0.919) практически не уступает лучшему reward (agg discounted_sum, 0.932).
5. Random никогда не достигает цели.




Рис. 2: Распределение CLIP scores среди 64 heuristic candidates на нескольких шагах эпизода.




Рис. 3: Пример воображаемых rollout'ов: лучшая, медианная и худшая траектории среди 64 heuristic candidates.




Рис. 4: Кривые лосса при обучении world model (шаг 9550).

5. Обсуждение

5.1. Failure modes

Режим max для CLIP не работает. Причина: max-скор поощряет единственный кадр, случайно захвативший зелёный пиксель, но соответствующая траектория может не вести к цели. Discounted_sum, напротив, требует consistent progress на всей траектории. Примечательно, что reward predictor нечувствителен к этому эффекту: все его max-стратегии дают 100% success.

CLIP не видит цель на ранних шагах. Когда агент далёк от цели, все декодированные rollout'ы выглядят одинаково (пустой коридор), scores неразличимы — выбор действия практически случайный.

Uniform Random Shooting проигрывает эвристике. При равномерном сэмплировании 64 кандидатов из 3 действий на 15 шагов большинство траекторий бессмысленны (частые повороты без продвижения). Эвристика (80% forward) даёт заметно лучший success rate; uniform RS не вошла в финальный протокол по этой причине.

CEM на малом budget сходится к локальному оптимуму. При $K = 3$ и $N_{\text{elite}} = 6$ распределение быстро схлопывается в субоптимальное действие. Увеличение до 5-10 итераций должно повысить качество, но растёт и latency. CEM также не вошёл в итоговый протокол из-за нестабильности на текущих параметрах.

World model drift на длинных rollout'ax. Prior rollouts на 15 шагов визуально деградируют (размытие, артефакты декодера), что снижает качество CLIP-скоринга — много траекторий уходит в «шум». Reward predictor, обученный в латентном пространстве и регуляризованный через KL-дивергенцию, устойчивее к этому дрейфу: он не зависит от качества декодированных кадров. Этим отчасти объясняется его более низкая дисперсия (std 0.02–0.05 против 0.04–0.33 у CLIP).

5.2. Future work

1. **Ensemble scoring (CLIP + reward).** Reward predictor стабильнее и точнее, CLIP — семантически гибок. Их комбинация (например, взвешенная сумма $S = \lambda S_{\text{CLIP}} + (1 - \lambda) S_{\text{reward}}$) — естественный следующий шаг, адресующий главный experimental finding работы.

2. **Увеличить CEM budget.** $K = 3$, $N = 64$ — нижняя граница. 10+ итераций и 200+ кандидатов с early stopping по сходимости распределения должны дать существенный прирост качества.
3. **Goal-conditioned планирование.** Метод `set_goal()` в CLIPScorer уже реализован: проверить промпты вида "a key", "next to a wall" для оценки семантической гибкости подхода.
4. **Полноценный DreamerV3 (actor-critic).** Замена чистого MPC на learned policy поверх imagined rollouts актуальна при переходе на более сложные среды (DoorKey, MultiRoom). Текущий MPC с $N = 64$ уже решает Empty-6x6 на 100%; для масштабирования потребуется actor-critic.
5. **Замена CLIP на другую VLM.** SigLIP, EVA-CLIP, или VLM с better visual grounding могут улучшить скор на стилизованных кадрах.

Репозиторий

Код: https://github.com/mihalko711/tbank_intro_problem

Визуализации и GIF-траекторий: `./visualizations/`

- `plan_9_strategies.png` — bar chart всех 9 стратегий.
- `plan_candidates.png` — пример воображаемых rollout'ов.
- `plan_score_distribution.png` — распределение CLIP scores.
- `loss_009550.png` — кривые обучения.
- `decision_*.gif` — покадровая визуализация каждого метода на всём эпизоде.
- `plan_decision.gif` — сводный эпизод с CLIP-планировщиком.